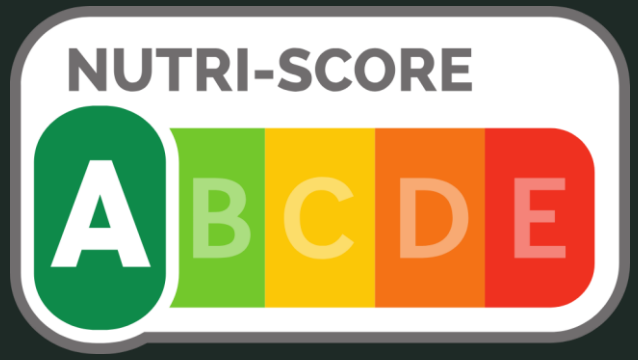
DATA ENGINEERING HS26 · PROJEKTARBEIT TEIL 1



Gut bewertet – aber auch gesund?

Wie aussagekräftig ist der Nutri-Score? Eine Analyse mit Open Food Facts

Cindy Sommer · Andrea Brunetto ZHAW School of Management and Law · Kolloquium 28. Oktober 2026

Ablauf

Teil A · Cindy Sommer

Konzeptionalisierung

1. Ausgangslage und Problemstellung
2. Forschungsfragen und Hypothesen
3. Vorgehen und Methoden
4. Entwurf des Lebenszyklus

Teil B · Andrea Brunetto

Technische Umsetzung

1. Datenquellen und Ingestion
2. Storage: Evaluation und Umsetzung
3. Transformation 1: Bereinigung, erste Tests
4. Fazit und Ausblick auf Teil 2

AUSGANGSLAGE

Der Nutri-Score soll den Einkauf vereinfachen

A–E

Fünfstufige Skala zur Nährwertqualität, berechnet pro 100 g bzw. 100 ml

7

Länder nutzen ihn, darunter die Schweiz. Algorithmus 2024 überarbeitet

10'000+

Produkte in der Schweiz tragen ihn, von 102 Unternehmen (Stand 9/2025)

In der Schweiz ist die Kennzeichnung **freiwillig**. Konsumentinnen und Konsumenten lesen ein A oder B oft als „gesund“.

Quellen: BLV (2025); CRESS (2024) · 03

PROBLEMSTELLUNG

Gute Werte können schlechte ausgleichen

Negativpunkte
Energie, Zucker, gesättigte Fettsäuren, Salz

–

Positivpunkte
Ballaststoffe, Protein, Obst, Gemüse, Nüsse

=

Score
→ Klasse A bis E

Nicht berücksichtigt

- Verarbeitungsgrad (NOVA-Gruppen)
- Zusatzstoffe wie Emulgatoren und Aromen
- Übliche Portionsgrösse (Bezug immer 100 g)

Beispiel Cerealien

Viel Zucker, aber auch viele Ballaststoffe: Die Positivpunkte drücken den Score nach oben, das Produkt erscheint als A.



FORSCHUNGSFRAGEN

Was wir mit den Daten beantworten wollen

FF1 Wie gut stimmen Nutri-Score und Verarbeitungsgrad (NOVA) überein?

FF2 In welchen Produktkategorien weicht der Nutri-Score am stärksten von Zuckergehalt und Zusatzstoffen ab?

FF3 Trifft die Kritik auch nach dem Algorithmus-Update 2024 noch zu? (vertieft in Teil 2)

HYPOTHESEN

Vier testbare Annahmen, α = 0,05

Nr.	Hypothese	Frage	Test
H1	Mehr als 20 % der Produkte mit Nutri-Score A/B sind hochverarbeitet (NOVA 4)	FF1	Einseitiger Binomialtest
H2	Nutri-Score-Klasse und NOVA-Gruppe hängen nur schwach zusammen (Cramér's V < 0,3)	FF1	χ^2-Test, Cramér's V
H3	Mindestens 10 % der Frühstückscerealien mit A/B enthalten über 22,5 g Zucker pro 100 g	FF2	Einseitiger Binomialtest
H4	Anzahl Zusatzstoffe und Nutri-Score-Punkte korrelieren höchstens schwach ($\lvert\rho\rvert < 0,2$)	FF2	Spearman-Korrelation

22,5 g/100 g = Grenze „hoher Zuckergehalt“ der UK Food Standards Agency · Schwellen vorläufig · 06

VORGEHEN UND METHODEN

Von der Frage zur geprüften Hypothese

1

Konzept

Fragen und Hypothesen festlegen

2

Beschaffung

Bulk-Export laden, auf Schweiz filtern

3

Speicherung

Rohdaten und Stufen in Parquet und DuckDB

4

Analyse

Bereinigen, explorieren, testen

5

Serving

Teil 2: ML-Modell oder KI-Anwendung

Werkzeuge

Python · pandas | DuckDB · SQL | SciPy (Tests) | Jupyter Notebooks | GitHub (Abgabe-Branch)

ENTWURF DATA-ENGINEERING-LEBENSZYKLUS

Fünf Phasen, getragen von sechs Unterströmungen

Generation
Hersteller und Freiwillige erfassen Produkte

→

Ingestion
Nächtlicher Bulk-Export, Batch

→

Storage
Parquet und DuckDB in drei Stufen

→

Transformation
Bereinigen, Merkmale bilden, testen

→

Serving
Teil 2: Modell oder KI-App

Unterströmungen

Security: keine Personendaten, Lizenz (ODbL) beachten

Architektur: lokal, schlank, umkehrbare Entscheide

Data Management: Data Dictionary, Snapshot-Datum

Orchestrierung: ein Skript pro Schritt, feste Reihenfolge

DataOps: Qualitätschecks mit Protokoll

Software Engineering: Git, kommentierter Code

INGESTION · DATENQUELLEN

Eine Hauptquelle, zwei Referenzen

Quelle	Inhalt	Rolle
Open Food Facts	Nährwerte, Nutri-Score, NOVA, Zusatzstoffe, Kategorien	Hauptquelle
UK Food Standards Agency	Ampel-Grenzwerte für Zucker, Fett, Salz	Referenz für H3
BLV	Liste der Nutri-Score-Marken in der Schweiz	Kontext

105'693

Produkte mit Bezug Schweiz in Open Food Facts

Snapshot 6.10.2026

Offene Daten: Lizenz ODbL, frei nutzbar mit Quellenangabe.

Achtung: Daten von Freiwilligen erfasst, also lückenhaft und fehleranfällig.

Quellen: Open Food Facts (2026); BLV (2025) · 09

INGESTION · DATENBESCHAFFUNG

Batch-Import aus dem nächtlichen Export

Export laden
Parquet-Datei von Hugging Face

→

Filtern
Nur Produkte mit Land Schweiz

→

Auswählen
15 relevante Spalten, Nährwerte entpackt

→

Ablegen
Bronze-Stufe, mit Datum im Namen

Warum Batch statt Streaming?

Die Quelle aktualisiert nur einmal pro Nacht, und unsere Analyse ist nicht zeitkritisch.

Warum Export statt API?

Die API ist für Einzelabfragen gedacht. Massenabfragen werden blockiert, der Export ist der vorgesehene Weg.

Gesamtdatenbank als CSV: ca. 0,9 GB komprimiert, ca. 9 GB entpackt (Open Food Facts, 2026) · 10

STORAGE · EVALUATION

Drei Optionen im Vergleich

Kriterium	PostgreSQL	MongoDB	DuckDB + Parquet
Verschachtelte Felder	mittel (JSONB)	gut	gut (Struct, List)
Analytische Abfragen	mittel	schwach	gut (spaltenbasiert)
Einrichtung	Server nötig	Server nötig	eingebettet, ohne Server
Datenmenge lokal	gut	gut	gut, liest nur benötigte Spalten
Viele Nutzer gleichzeitig	gut	gut	schwach

Entscheid: DuckDB + Parquet. Unser Fall ist Analyse durch zwei Personen, kein Mehrbenutzerbetrieb.

STORAGE · IMPLEMENTIERUNG

Drei Stufen von roh bis auswertbar

Bronze

Rohdaten als Parquet, unverändert, mit Snapshot-Datum

→

Silver

DuckDB-Tabelle: bereinigt, typisiert, ohne Duplikate

→

Gold

Auswertungstabellen pro Hypothese, z. B. Nutri-Score × NOVA

Beispiel: Silver-Tabelle aus Bronze erzeugen

```
CREATE TABLE silver_products AS
SELECT * EXCLUDE (f_duplikat, f_unmoeglich, …)
FROM silver_flagged -- Bronze + ein Flag pro Regel
WHERE NOT (f_duplikat OR f_unmoeglich OR …)
```

TRANSFORMATION 1 · INITIALE BEREINIGUNG

Nur jedes fünfte Produkt ist auswertbar

Regel	Prüfung	Betroffen
Duplikate	Gleicher Barcode mehrfach	1
Unmögliche Werte	Nährwert unter 0 oder über 100 g pro 100 g	267
Summe	Fett + Kohlenhydrate + Protein + Salz über 100 g	218
Energie	Abweichung über 20 % von 4·KH + 4·Protein + 9·Fett	3'933
Zielwerte fehlen	Kein Nutri-Score oder keine NOVA-Gruppe	82'186
Getränke	Separat, eigener Algorithmus	8'225

Vorher (Bronze)

105'693

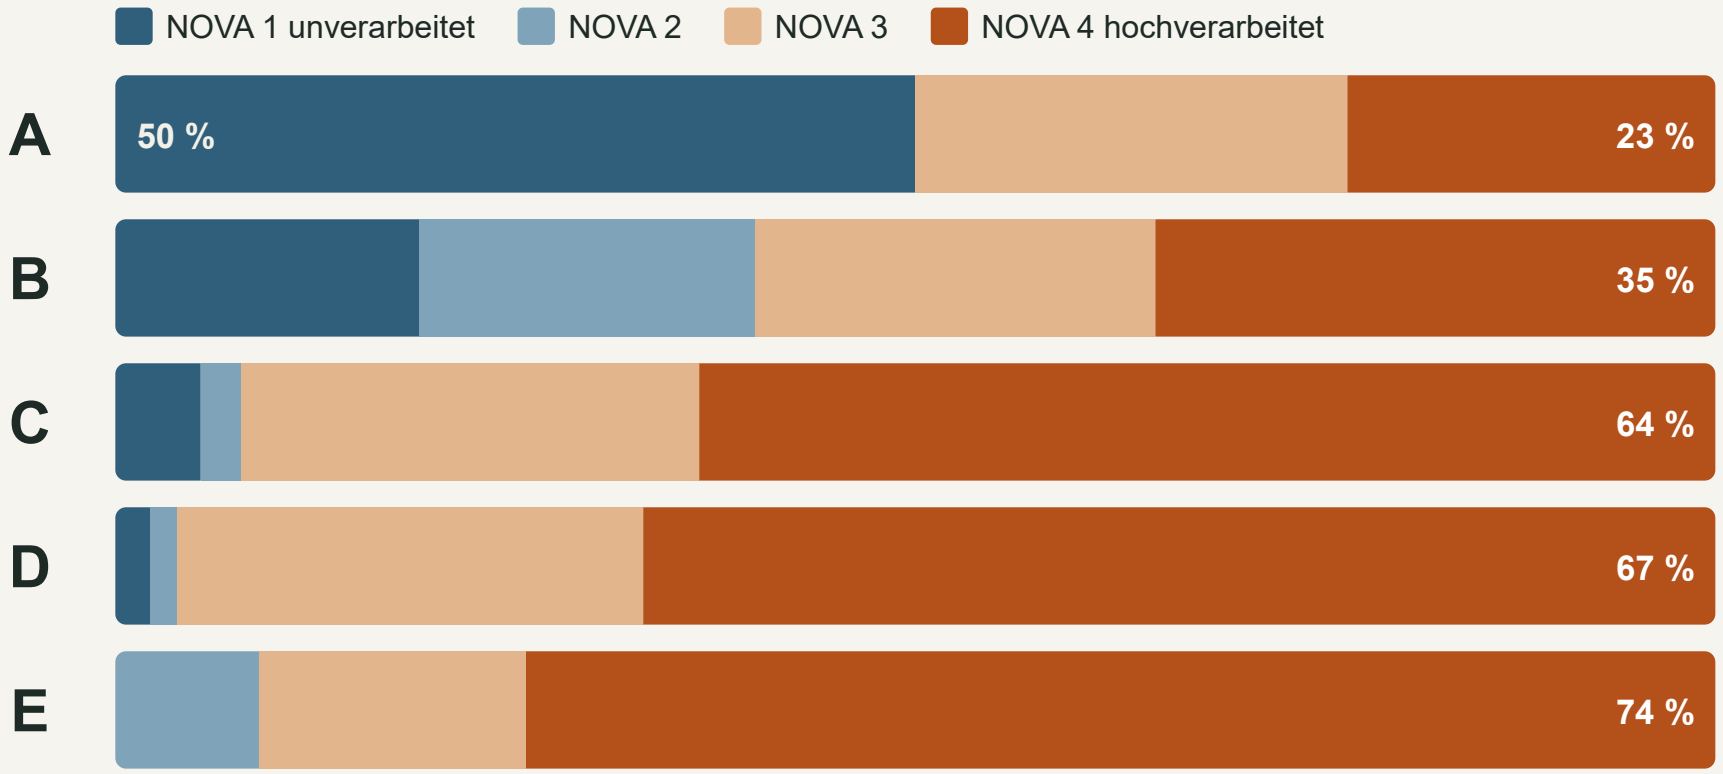
Nachher (Silver)

22'949

davon 20'454 Lebensmittel ohne Getränke

TRANSFORMATION 1 · INITIALE ANALYSE

Je schlechter der Score, desto mehr Hochverarbeitetes



Aber:

Auch bei A ist fast jedes vierte Produkt hochverarbeitet, bei B mehr als jedes dritte.

Anteil je Nutri-Score-Klasse, Werte gerundet · n = 20'454 Lebensmittel ohne Getränke · Snapshot 6.10.2026 · 14

TRANSFORMATION 1 · INITIALE ANALYSE UND HYPOTHESENTEST

Jedes vierte gute Label steht auf hochverarbeiteten Produkten

H1 · NOVA 4 unter A/B · bestätigt

27,7 %

über der 20-%-Schwelle · n = 4'936 · p < 0,001

H2 · Nutri-Score × NOVA · verworfen

V = 0,36

mittlerer statt schwacher Zusammenhang · n = 20’454 (V < 0,3)

H3 · Zuckerreiche Cerealien mit A/B · verworfen

1,1 %

weit unter 10 % · n = 281 · p = 1,00

H4 · Zusatzstoffe vs. Score · verworfen

ρ = 0,36

mehr Zusatzstoffe, schlechterer Score · n = 19’870 (p < 0,2)

Vorläufig · Snapshot 6.10.2026 · Lebensmittel ohne Getränke · α = 0,05 · 15

FAZIT UND AUSBLICK

Der Score ist besser als sein Ruf, aber blind für Verarbeitung

Erreicht in Teil 1

- Pipeline von 105'693 Produkten zu 22'949 auswertbaren
- Speicherung in drei Stufen mit DuckDB
- 27,7 % der A/B-Produkte sind hochverarbeitet
- Zuckerreiche Cerealien mit A/B sind selten

Geplant für Teil 2

- FF3: Version der Scores klären, alt und neu vergleichen
- Verzerrung durch fehlende Werte prüfen
- Serving Option B: NOVA 4 aus Nährwerten vorhersagen, mind. 2 Modelle

Quellen

- BLV (2025). Unternehmen und Marken, die sich in der Schweiz für den Nutri-Score engagieren. Stand 30.09.2025. Bern: BLV.
- CRESS (2024). Nutri-Score update. https://cress-umr1153.fr/en/nutri-score-update
- Cramér, H. (1946). Mathematical Methods of Statistics. Princeton: Princeton University Press.
- Department of Health & Food Standards Agency (2016). Guide to creating a front of pack (FoP) nutrition label. London.
- Merz, B. et al. (2024). Nutri-Score 2023 update. Nature Food, 5(2), 102–110.
- Monteiro, C. A. et al. (2019). Ultra-processed foods: what they are and how to identify them. Public Health Nutrition, 22(5), 936–941.
- Open Food Facts (2026). Data, API and SDKs. https://world.openfoodfacts.org/data (Lizenz ODbL)
- Reis, J. & Housley, M. (2022). Fundamentals of Data Engineering. Sebastopol: O'Reilly Media.
- Verordnung (EU) Nr. 1169/2011 betreffend die Information der Verbraucher über Lebensmittel, Anhang XIV.